电子科技大学实验报告

学生姓名: 郭宇航 学号: 2016100104014 指导教师: 徐行

一、实验项目名称:基于词袋模型的图像分类

二、实验原理:

BOW(Bag of words)模型最初被应用于文本分类中,将文档表示为特征矢量。它的基本思想就是假定对于一个文本,忽略其语序,语法,句法等等。仅仅看做词汇的集合,而文本中的词汇都是独立的。简单来说就是每篇文档都可以看做一个袋子里面装的是词汇。词袋模型由此得名。举个例子,假设我们有两个文档:

文档一: Bob likes to play basketball, Jim likes too.

文档二: Bob also likes to play football games.

基于这两个文本文档,构造一个词典:

Dictionary =

{1:"Bob", 2. "like", 3. "to", 4. "play", 5. "basketball", 6. "also", 7. "football", 8. "games", 9. "Jim", 10. "too" }.

这个词典一共包含 10 个不同的单词,利用词典的索引号,上面两个文档每一个都可以用一个 10 维向量表示 (用整数数字 0~n (n 为正整数)表示某个单词在文档中出现的次数):

1: [1, 2, 1, 1, 1, 0, 0, 0, 1, 1]

2: [1, 1, 1, 1, 0, 1, 1, 1, 0, 0]

向量中每个元素表示词典中相关元素在文档中出现的次数(下文中,将用单词的直方图表示)。不过,在构造文档向量的过程中可以看到,我们并没有表达单词在原来句子中出现的次序(这是本 Bag-of-words 模型的缺点之一,不过瑕不掩瑜甚至在此处无关紧要)。

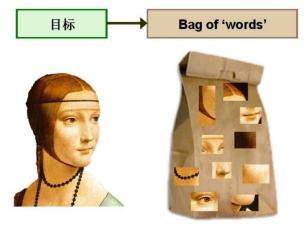


图 1: 将词袋模型应用于图像分类

SIFT 特征虽然也可以描述一幅图像但是每个 SIFT 特征的维度都是 128 维,而且一幅图像的 SIFT 特征往往包含了成百上千个 SIFT 特征矢量,进行相似度的计算时计算量非常庞大。通常的做法是使用聚类算法对这些矢量进行聚类,然后用聚类的每个簇代表 BOW 模型的一个视觉词,将一幅图像的 SIFT 矢量映射到视觉词序列生成码本,从而使得图像可以通过码本矢量来表示,计算效率大大提高。

构建 BOW 模型码本的步骤如下:

- (1) 假设训练集共有 M 张图片,对训练图像进行预处理包括图像的增强,分割,图像格式的统一化等等。
- (2) 提取 SIFT 特征,对每一张图片提取 SIFT 特征,每个图像提取的 SIFT 特征数量不定。每个 SIFT 特征用一个 128 维的描述子矢量表示,假设 M 张图片共有 N 个 SIFT 特征。
- (3) 使用 K-means 算法对 (2) 中提取出来的 N 个 SIFT 特征进行聚类将 N 个 向量划分为 K 个簇,码本的长度也就为 K, 计算每一张图片的 SIFT 特征 到这个码本(dict)的距离并将其映射到最近的视觉词中,词频+1,完成这一步后每一张图像就成为了一个与视觉词序列相对应的词频矢量。

三、实验目的:

图像识别:特征提取+分类器的构建和使用

四、实验内容:

主要任务:

- (1) 图像词袋特征的表示: tiny 特征和 SIFT 特征
- (2) 词袋的构建: 从训练数据中获取特征进行 K-means 聚类
- (3)分类器的构建: KNN 方法(欧氏距离相似度计算归类)和 SVM(一对多策略)

需要完善的代码:

- (1) get tiny images()
- (2) Bulid vocabulary() 其中包括 SIFT 特征的提取与词袋模型的建立
- (3) get_bags_of_words() 根据词袋获取测试图片的直方图特征表示
- (4) SVM_classify()和 Nearest_neighbor_classify()分类器函数的完善

五、实验步骤:

一、完善 get_tiny_images()函数: 完善代码如下:

def get_tiny_images(image_paths):

This feature is inspired by the simple tiny images used as features in 80 million tiny images: a large dataset for non-parametric object and

```
Transactions on Pattern Analysis and Machine Intelligence, vol.30(11),
               path to an image on the filesystem.
aliasing artifacts that may throw off your comparisons. See the docs for
Suggested functions: skimage.transform.resize, skimage.color.rgb2grey,
#TODO: Implement this function!
dimension = 9
image_tiny = np.empty((len(image_paths),dimension**2),dtype=float)
for i in range(len(image_paths)):
   image = cv2.imread(image_paths[i])
   image = cv2.cvtColor(image,cv2.COLOR_BGR2GRAY)
   min_dimension = np.min(image.shape)
   image = image[:min_dimension,:min_dimension]
```

```
image = cv2.resize(image,(dimension,dimension))
#将图片的像素点归一化
image = image/np.sum(image)
image_tiny[i,:] = np.resize(image,[dimension,dimension])
print(image_tiny.shape)
return image_tiny
```

get_tiny_images()主要目的是对图像进行简单的处理,其中包括:图像的剪裁,下采样缩放,图像的像素点归一化等等。

这里的输入参数 image_paths 是所有训练图片的路径,通过 for 循环进行遍历读取,image_tiny 用于存放已经得到的 tiny 的图像,另外其中调用了opencv-python 中的大量 API 函数,包括 imread()以及 cvtColor()等。流程大致为:首先读入图片,对图片进行灰度化,然后进行 crop 剪裁图片,剪裁后缩放 resize到固定的尺寸,这里给的尺寸为 9*9.最后再归一化处理,并 reshape 为行向量。二、完善 build_vocabulary()函数:

```
完善代码如下:
def build_vocabulary(image_paths, vocab_size):
   You'll need to generate HOG features using the skimage.feature.hog()
   The documentation is available here:
   important arguments to consider:
```

16 cells, was equivalent to setting this argument to (4,4). implementation, each cell was 4 pixels by 4 pixels, so (4,4). It is up to you to choose your cells per block and pixels per cell. Choose classification results. For each cell, HOG produces a histogram (feature

```
can find feature vectors in the original sized image.
   absolutely massive vocabulary. That would make matching inefficient AND
(vocab size)
sklearn.cluster.KMeans
   the max iter argument to something low (we used 100) and be patient. You
   #TODO: Implement this function!
   SIFT_features = []
   sift model = cv2.xfeatures2d.SIFT create()
   for i in range(len(image_paths)):
       image = cv2.imread(image_paths[i])
       image_gray = cv2.cvtColor(image_cv2.COLOR_BGR2GRAY)
       location,sift features =
sift model.detectAndCompute(image_gray, None)
       for j in sift_features:
           SIFT_features.append(j)
   SIFT features = np.array(SIFT features)
   kmeans_model =
KMeans(n_clusters=vocab_size,max_iter=100).fit(SIFT_features)
   cluster_centers = kmeans_model.cluster_centers_
   return np.array(cluster_centers)
```

这一部分的代码主要流程有两项,第一项是获取每个图片的 SIFT 特征,这里使用的是 opencv-python 中的函数 xfeatures2d.SIFT_create(),这一函数有两个返回值,第一个是 location 即 SIFT 特征的位置,第二个是 SIFT 特征矢量,SIFT 特征矢量为一个 N*128 的矩阵,其中 N 的值每一张图片都不相同;第二项是对所有图像的 SIFT 特征进行 K-means 聚类,首先先将所有的 SIFT 特征组成一个大矩阵,矩阵的行为所有的 SIFT 矢量的数量,列数为 128.通过 K-means 聚类可以得到最终我们需要的所有簇的中心向量,这些中心向量就会作为最终的字典dict。

三、完善 get_bags_of_words()函数:

完善代码如下:

```
def get_bags_of_words(image_paths):
   Use the same hog function to extract feature vectors as before (see
   both build vocabulary and get bags of words! Otherwise, you will end up
   vocab = np.load('vocab.npy')
   print('Loaded vocab from file.')
   sift model = cv2.xfeatures2d.SIFT create()
   hist_vector = np.zeros([len(image_paths),len(vocab)])
   for i in range(len(image_paths)):
       image = cv2.imread(image_paths[i])
       image_gray = cv2.cvtColor(image,cv2.COLOR_BGR2GRAY)
       location,sift_features =
sift model.detectAndCompute(image_gray, None)
```

这一部分主要是基于得到的 SIFT 特征的 dict 得到每一个图像的特征表示。主要流程是首先读取 vocab.npy 得到之前的 dict,然后重新计算每一张图片的 SIFT 特征向量,计算其到 dict 每一个的矩阵,选择距离最小那个,并对其计数+1,简而言之就是计算每一张图片的所有 SIFT 特征到 dict 的距离,选择距离最小的表示次 SIFT 特征属于的类别,对这一类别的计数器加 1,最终得到一个图像的特征向量的表示。最后的返回值为所有图片的特征向量组成的矩阵。

四、完善 svm_classify()函数

完善代码如下:

```
We suggest you look at the sklearn.svm module, including the LinearSVC class. With the right arguments, you can get a 15-class SVM as described above in just one call! Be sure to read the documentation carefully.

# TODO: Implement this function!

#训练 SVM 分类器

SVM_classification =

LinearSVC(penalty='12',multi_class='ovr',random_state=0,max_iter=100)

SVM_classification.fit(train_image_feats,train_labels)

#使用 SVM 分类器得到预测结果

output_labels = []

for i in test_image_feats:

output_labels.append(SVM_classification.predict(i.reshape(1,-1)))

return np.array(output_labels)
```

这一部分代码比较简单,输入的参数分别为训练数据和训练的标签以及测试集的数据。构造 SVM 的分类器,这里使用到的是 sklearn 这个库,调用的是线性的 LinearSVC 模型,参数选取上采用 L2 的正则化,多分类参数选取'ovr',最大迭代次数为 100 次。将训练数据及标签带入到模型训练,最后将测试集带入模型得到最后的预测结果,保存为向量并作为函数的返回值。

五、完善 nearest_neighbor_classify()函数:

完善代码如下:

```
Additionally, past a certain threshold the classifier is considering so
   k = 9
feature
   distances = cdist(test image feats, train image feats, 'euclidean')
   #TODO:
   labels = []
   for i in range(len(test_image_feats)):
       nn = np.argsort(distances[i])
       nn_label = np.array(train_labels)[nn[:k]]
       mode,cnt = stats.mode(nn label)
```

print(mode) labels.append(mode[0]) return np.array(labels)

这一部分代码的构建与 SVM 分类器的构建相类似,因此不再多赘述。

六、实验数据及结果分析:

在完成 student.py 文件的完善之后,下面运行 main.py 文件测试代码和模型的效果,训练的数据共有 15 个类别,包括 bedroom, coast 等等图片。每一类别中选取了 100 张图片,共计 1500 张图片的数据。测试数据同样是 15 个类别,总数多于 1500 张。

下面给出一些模型的详细参数设置:

- 1)在 tiny 特征中给出的单个图片的尺寸为 9*9
- 2)词袋模型构建时使用 sift 特征, 之后 K-means 聚类选取 cluster 的个数为 500 个
- 3)词袋模型中的视觉词的个数为 300
- 4)KNN 分类器中的 k 选取为 10

最终得到的结果如下:

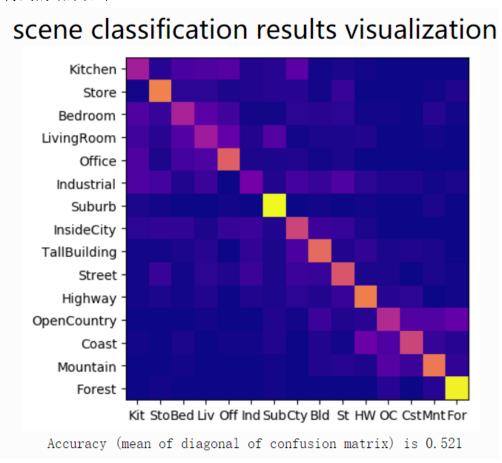


图 2: 混淆矩阵以及测试准确率示意图

具体每一个类别分类的准确率如下:

Category name	Accuracy	Sample training images		Sample true positives		False positives with true label		False negatives with wrong predicted label	
Kitchen	0. 330				- Lung	Bedroon	LivingRoom	Highway	Mountain
Store	0. 640	ĖĖ				Store	Store	Highway	Suburb
Bedroom	0. 340					LivingRoom	Bedroon	Forest	Industrial
LivingRoom	0. 320					Hi ghway	Kitchen	Forest	Office
Office	0. 540		and d	ÞΓ		Office	LivingRoom	TallBuilding	Store
Industrial	0. 210				7	Industrial	Industrial	Office	Suburb
Suburb	0. 920	1284				LivingRoom	Street	Office	Highway
InsideCity	0. 460				8	Street	Industri al	Suburb	LivingRoom
[allBuilding	0. 570		3			OpenCountry	TallBuilding	Industrial	Highway
Street	0. 510					Street	Street	Kitchen	TallBuilding
Highway	0. 630			C. 110		Highway	Coast	Forest	Mountain
OpenCountry	0. 370		7.			OpenCountry	OpenCountry	Highway	Highway
Coast	0. 460				-	Coast	Coast	Mountain	LivingRoom
Forest	0. 900				F.	OpenCountry	Forest	Industrial	Bedroom
Category name	Accuracy	Sample training images		Sample true positives		False positives with true label		False negatives with wrong predicted label	

整体来看,总体分类准确率较低只有 52.1%,对于 15 个具体的类别来说,其中 Suburb 和 Forest 的分类准确率较高,可以达到 90%以上,而 kitchen, bedroom, living room, Industrial 等分类准确率较低,只有 30%左右。整体来看自然风景图片的预测准确率高于其他的一些图片,尤其是各类房间的照片。

七、实验结论:

本次实验主要实现了对于图像的特征提取与分类,提取特征的方法主要是基于 SIFT 特征然后聚类得到的 bag of words 模型,主要实现的功能包括 SIFT 特征的 提取与聚类,图片直方图特征的表示以及 SVM,KNN 两个分类器的构建。

分析最终实验得到的结果,最终预测的准确率只有 52.1%,偏低的原因分析下来,个人认为主要在于一些参数设置的问题,比如说 K-means 聚类时选取的簇的个数,考虑到 SIFT 提取了 1500 张图片的特征,每个图片有上百个 SIFT 特征,聚类时样本的数量应该会达到十万到百万级别的数据,因此聚类的簇选取应该更大一些,得到的视觉词的数量可以更多则最终可以得到的特征信息阅读,更加有利于分类。

另外还有观察所有类别的分类准确率我们可以发现,其中一些自然风景的照片分类的准确率明显高一些,究其原因个人认为是自然风景图片的特征更加容易获取,特别是特定场景下的一些自然风景,特征会非常明显,而一些家庭起居或者其他工业图片往往特征不那么鲜明,而且在 BOW 这种模型忽略了图像内部之间的关联性后会使得最终的图像分类结果比较差。

八、总结及心得体会:

Project3 这个实验比较有意思,但是中途也遇到了很多的麻烦,首先第一个是在使用 opencv-python 这个库的时候发现想调用有关 SIFT 特征提取的方法时出现了问题,主要是在于版本的兼容性问题,需要使用 3.4.2.16 左右的版本。另外一个比较坑的地方是 skimage 库中的 resize 函数花费的时间是 opencv-python 中 resize 函数的很多很多倍,因此一开始使用 skimage 程序运行起来会非常的费时。当然在使用了 opencv-python 后跑程序仍然花了很多的时间,主要原因是数据量比较大,在构建 BOW 模型的视觉词 vocab 时非常的费时,因此这对于调参数带来了不小的影响。

九、对本实验过程及方法的改进建议:

- (1) 可以考虑对比使用一些其他特征提取的方法来进行图像的分类。
- (2) 可以引入一些深度网络模型来讲行图像的分类识别。

报告评分:

指导教师签字: